

Note de mise à jour de l'analyse

Projet : Choisir son pays de destination selon sa profession

Date de mise à jour : 28 septembre 2026

Cette note complète le rapport académique original du projet. Elle décrit la version actuelle du pipeline Python et des fichiers CSV. Elle ne remplace pas le rapport de groupe et ne met pas à jour les captures ou le classeur Tableau, qui restent des instantanés de la version antérieure.

Pourquoi cette mise à jour

La relecture du dépôt a révélé un écart entre le rapport, le notebook et les données publiées. Le notebook ne recalculait pas les scores par profession, les fichiers finaux n'étaient pas reproductibles à partir des cellules, et le texte du rapport décrivait une normalisation différente de celle réellement utilisée. Le pipeline a été complété pour produire les exports depuis les sources, avec des contrôles explicites.

Données et périmètre

La base brute contient 236 pays et territoires, avec neuf indicateurs numériques et leurs catégories. Les zéros utilisés comme codes de valeurs absentes sont convertis en valeurs manquantes. Une seconde source fournit la correspondance pays-continent.

Les noms de pays sont normalisés avant la fusion ; trois alias explicites couvrent les différences d'appellation entre les fichiers. La jointure conserve 230 pays. Six noms restent sans équivalent dans la source des continents : Aland Islands, Alderney, Bonaire, French Southern Territories, Kosovo (Disputed Territory) et Saint Helena. Le pipeline affiche ces exclusions au lieu de les masquer.

La base finale contient 34 colonnes, dont les indicateurs apurés, les versions normalisées, le continent, cinq scores par profil et le nombre d'indicateurs imputés pour chaque pays.

Méthode actuelle

Les valeurs manquantes des neuf indicateurs numériques sont imputées avec `KNNImputer` et $k = 5$. Avant le calcul des distances, les variables sont ramenées sur une échelle commune avec `MinMaxScaler`; après l'imputation, elles sont reconverties dans leurs unités d'origine. Cette précaution empêche les variables à grande amplitude de dominer mécaniquement les distances. KNN est une méthode d'imputation par voisins, pas une méthode de « Deep Learning ».

Les catégories manquantes sont complétées séparément pour chaque indicateur, à partir des seuils observés dans les catégories existantes. Le nombre initial de valeurs imputées est conservé dans la colonne `Imputed values count`. Cette colonne informe sur la dépendance d'un pays aux estimations, sans constituer à elle seule une mesure de fiabilité.

Pour les scores professionnels, les huit indicateurs utilisés sont normalisés sur $[-1, 1]$. Le signe du coût de la vie, du prix immobilier rapporté au revenu, du temps de trajet et de la pollution est inversé afin qu'une valeur normalisée plus élevée contribue favorablement au score. Les cinq critères de chaque profil sont additionnés avec un poids égal. Le score théorique se situe donc entre -5 et 5.

Profil	Critères additionnés
Salarié	Coût de la vie, pouvoir d'achat, temps de trajet, sécurité, santé
Indépendant	Coût de la vie, prix immobilier / revenu, temps de trajet, pollution, climat
Étudiant	Coût de la vie, prix immobilier / revenu, temps de trajet, sécurité, santé
Touriste	Sécurité, pollution, climat, temps de trajet, coût de la vie
Sans emploi	Coût de la vie, prix immobilier / revenu, santé, sécurité, temps de trajet

Résultats recalculés

Les rangs ci-dessous sont calculés à partir de [data/quality_of_life_final_scores_profession.csv](#), sur les 230 pays présents dans cette base.

Pays	Général	Étudiant	Salarié	Indépendant	Touriste
Rwanda	228e	188e	38e	181e	1er
Bhoutan	50e	2e	9e	1er	4e
Tuvalu	32e	1er	1er	52e	21e
Luxembourg	1er	52e	15e	37e	37e
Andorre	18e	4e	6e	11e	3e

Le top 10 général partage de zéro à trois pays avec le top 10 d'un profil donné. Aucun pays ne figure à la fois dans le top 10 général et dans les top 10 des cinq profils.

Limites d'interprétation

- Les profils « étudiant » et « sans emploi » utilisent les cinq mêmes critères dans le même ordre ; leurs scores et leurs classements sont donc identiques. Il n'y a que quatre classements distincts.
- Les cinq critères sont pondérés à parts égales. Cette hypothèse n'est pas validée par une enquête auprès des personnes concernées et influence le résultat.
- L'imputation KNN crée des valeurs estimées. Par exemple, Montserrat a 8 indicateurs imputés sur 9 et se classe 7e pour le profil étudiant ; Wallis And Futuna en a 9 sur 9. Ces rangs doivent être lus avec cette réserve.
- La fusion exclut les six pays et territoires indiqués plus haut. Une table de correspondance par code ISO, si disponible dans les deux sources, serait préférable à une jointure par nom.
- Le classement mesure uniquement les indicateurs inclus dans le modèle. Il ne prend pas directement en compte les visas, le droit au travail, les frais d'études, les revenus personnels, la langue ou les préférences individuelles. Il ne constitue pas une recommandation personnalisée de déménagement.

Sources et fichiers

- Base de qualité de vie : [Quality of Life for Each Country, Kaggle](#). La page renvoie aux conditions d'utilisation des données Numbeo : [Numbeo](#).
- Correspondance pays-continent : [World Population Dataset, Kaggle](#). La page Kaggle indique une licence « Other » ; vérifier les conditions auprès de la source avant redistribution.
- Notebook reproductible : [traitement_donnees.ipynb](#).

- Base des scores recalculés : [data/quality_of_life_final_scores_profession.csv](#).

Le PDF original et le classeur Tableau sont conservés comme livrables historiques. Le classeur et les captures doivent être actualisés dans Tableau avant d'être présentés comme représentatifs des résultats de cette note.