

PROJET DE DATAVISUALIZATION

ETUDIANT

ADDOH N'chot Serge

KONE Abdoulaye

KOUASSI Yao Kra Emmanuel

ENSEIGNANT

Mme LALY MIRABELLE

Table des matières

INTRODUCTION	2
I- JUSTIFICATION DU CHOIX DE LA PROBLÉMATIQUE	2
II- NETTOYAGE DE LA BASE DE DONNÉES	2
III - APPROCHE ADOPTÉE POUR ATTEINDRE L'OBJECTIF	3
1. Représentation graphique des variables jugées importantes pour tous.....	3
2. Présentation d'ensemble des autres variables	4
3. Représentation de la variable "Quality of Life"	4
4. Représentation de la variable catégorielle Sécurité	5
5. Quand est-il de la pollution à l'échelle mondiale ?	6
6. Tableau de bord 1	6
7. Tableau de Bord 2	7
8. Création de la feuille choix_par_profession.....	7
CONCLUSION	12
Tables des illustrations.....	13

INTRODUCTION

La présentation des données est une tâche assez importante pour non seulement les utilisateurs des données, mais aussi pour le statisticien. Savoir ce que l'on veut présenter, savoir comment le présenter est assez important. C'est pourquoi nous sommes appelés à travailler sur une base de données qui traite de la qualité de la vie dans différents pays du monde. Cette qualité de vie est abordée sous plusieurs angles. Dans le présent projet, notre objectif sera de permettre à un individu de faire le meilleur choix de destination selon sa situation professionnelle.

I- JUSTIFICATION DU CHOIX DE LA PROBLÉMATIQUE

La base de données contient plusieurs variables qui, dans l'ensemble, situent sur la qualité de vie dans un pays. Selon la variable, un score est dressé en vue de classer les pays du monde. Pour un individu qui voudrait voyager vers un pays, soit pour des vacances ou en guise de s'y installer ou pour des études, il est crucial de connaître la classification des pays selon un indicateur donné. Il est tout à fait cohérent de visualiser un tableau de bord qui fait le classement de la variable « **Quality_of_life** ». Cependant, les déterminants du choix d'un pays dépendent sans doute de la profession. En effet, un étudiant n'aura pas les mêmes critères de choix de son pays de destination qu'un homme d'affaires ou un salarié.

Il convient donc de s'interroger de la sorte : **“Quel est le choix optimal de destination d'un individu selon sa situation professionnelle”**

Dans le présent projet, nous nous attelons à permettre à tout individu de choisir son pays de destination sans assez de remords.

II- NETTOYAGE DE LA BASE DE DONNÉES

La base de données primitive (236 pays et territoires, données Numbeo) regorge des valeurs manquantes pour plusieurs variables, les valeurs nulles y étant traitées comme manquantes. Le système de correction automatique de l'application tableau ne permettait pas d'affiner la base pour notre projet. Les pays pour lesquels des valeurs manquaient étaient assez pour qu'on les supprime. C'est pourquoi, nous avons décidé d'utiliser la méthode « **KNN** » (k plus proches voisins) pour imputer via **Python** les neuf indicateurs numériques manquants.

Nous avons choisi comme paramètre $k=5$: les valeurs sont apurées par la moyenne des 5 voisins les plus proches. Les variables sont mises à l'échelle avant le calcul des distances, puis reconverties dans leurs unités d'origine. Cette méthode se justifie, car les pays aux profils d'indicateurs proches ont tendance à avoir des valeurs proches. Les catégories manquantes sont recalculées à partir des seuils observés ; la base finale conserve le nombre d'indicateurs imputés par pays.

Pour visualiser par continent, nous avons utilisé une base externe (World Population Dataset, Kaggle). Après normalisation des noms et jointure, la base finale compte 230 des 236 pays de la base brute : quatorze correspondances ont été récupérées grâce à la normalisation et à trois alias explicites. Six territoires restent exclus, faute d'équivalent dans cette source : Aland Islands, Alderney, Bonaire, French Southern Territories, Kosovo (Disputed Territory) et Saint Helena.

III - APPROCHE ADOPTÉE POUR ATTEINDRE L'OBJECTIF

1. Représentation graphique des variables jugées importantes pour tous

Nous avons jugé que certaines variables sont importantes pour toutes les personnes qui veulent voyager. Ces variables sont la variable **"Safety"**, c'est-à-dire le niveau de sécurité du pays et la variable **"Pollution Value"** qui traite du niveau de pollution du pays.

Les représentations qui en découlent sont dans les figures ci-dessous.




Figure 1: Représentation de la variable "Safety" (non actualisée)




Figure 2: Reproduction de la variable pollution par pays (non actualisée)

2. Présentation d'ensemble des autres variables

Ici, nous représentons le reste des variables, à travers un filtre, l'on peut choisir la variable que nous souhaitons voir représentée. Le graphique est illustré ci-dessous.




Figure 3: Représentation des autres variables de la base (non actualisée)

Cette représentation donne également la possibilité de filtrer la visualisation à travers les continents.

3. Représentation de la variable "Quality of Life"

Cette représentation a été élaborée pour le choix d'un pays de destination selon l'ensemble des indicateurs de la base. Aucune spécificité n'est prise en compte.



Figure 4: Représentation de la qualité de vie par pays (non actualisée)

4. Représentation de la variable catégorielle Sécurité

Nous avons également fait une représentation globale des variables de catégorie permettant de comprendre la situation globale dans le monde selon les variables comme (**le niveau de sécurité, le score de pollution**) aussi une représentation par rapport aux différents continents.




Figure 5: Représentation de la catégorie du niveau de « Safety » dans le monde (non actualisée)

5. Quand est-il de la pollution à l'échelle mondiale ?




Figure 6: Représentation de la pollution par continent (non actualisée)

Le graphique ci-dessous nous montre un état de la pollution à l'échelle mondiale. L'on voit le continent le plus pollué dans le monde jusqu'au continent le plus sain en termes de pollution.

6. Tableau de bord 1

Dans ce premier tableau de bord, nous avons fait un regroupement des feuilles.




Figure 7: Tableau de bord 1 (non actualisée)

7. Tableau de Bord 2




Figure 8: Tableau de bord 2 (non actualisée)

8. Création de la feuille choix_par_profession

Plus haut, nous avons expliqué le petit inconvénient de classer les pays en considérant que les variables sont déterminantes pour tous les individus.

Dès lors, nous avons construit des scores en fonction des professions. Huit indicateurs ont d'abord été normalisés entre -1 et 1. Ensuite, le signe des indicateurs dont la hausse décourage un voyage dans un pays donné (coût de la vie, prix de l'immobilier par rapport au revenu, temps de trajet et pollution) a été inversé (multiplication par -1). Dès lors, pour chaque profession, nous avons additionné, avec un poids égal, les cinq critères qui lui sont propres. Ainsi, chaque pays détient un score selon la profession. C'est pourquoi, les pays peuvent être à nouveau classés selon chaque profil.

Ci-dessous, une présentation du regroupement des variables par profession.

8.1. Salarié

- **Cost of Living Value (Coût de la vie)** : C'est un facteur important, car il impacte directement le pouvoir d'achat et la capacité d'épargne.
- **Purchasing Power Value (Pouvoir d'achat)** : Lié au coût de la vie, il détermine la qualité de vie possible avec le salaire local.
- **Traffic Commute Time Value (Temps de trajet domicile-travail)** : Un temps de trajet court améliore la qualité de vie et réduit le stress.
- **Safety Value (Sécurité)** : Essentielle pour la tranquillité d'esprit et la protection des biens.
- **Health Care Value (Santé)** : L'accès à des soins de qualité est important pour la santé et le bien-être.

8.2. Indépendant

- **Cost of Living Value (Coût de la vie) :** Un coût de vie bas permet de maximiser les revenus et de réinvestir dans l'activité.
- **Property Price to Income Value (Prix de l'immobilier par rapport au revenu) :** L'accessibilité à la propriété est importante pour la stabilité et l'investissement.
- **Traffic Commute Time Value (Temps de trajet) :** La mobilité est importante pour les rendez-vous clients et les déplacements professionnels.
- **Pollution Value (Pollution) :** Un environnement sain favorise la productivité et le bien-être.
- **Climate Value (Climat) :** Un climat agréable peut être un facteur de motivation et de bien-être.

8.3. Étudiant

- **Cost of Living Value (Coût de la vie) :** Le budget étudiant est souvent limité, donc un coût de vie bas est primordial.
- **Property Price to Income Value (Prix de l'immobilier par rapport au revenu) :** L'accès à un logement abordable est essentiel.
- **Traffic Commute Time Value (Temps de trajet) :** Des transports en commun efficaces et des temps de trajet courts facilitent l'accès aux études.
- **Safety Value (Sécurité) :** Un environnement sûr est important pour se sentir à l'aise et étudier sereinement.
- **Health Care Value (Santé) :** L'accès à des soins de santé abordables est important pour les étudiants.

8.4. Touriste

- **Safety Value (Sécurité) :** La sécurité est primordiale pour profiter pleinement du voyage.
- **Pollution Value (Pollution) :** Un environnement propre et agréable améliore l'expérience touristique.
- **Climate Value (Climat) :** Le climat est souvent un facteur déterminant dans le choix d'une destination.
- **Traffic Commute Time Value (Temps de trajet) :** Des transports efficaces et des temps de trajet courts permettent de maximiser les visites.
- **Cost of Living Value (Coût de la vie) :** Un coût de la vie raisonnable permet de profiter du voyage sans se ruiner.

8.5. Sans emploi :

- **Cost of Living Value (Coût de la vie) :** Un coût de vie bas est essentiel pour survivre avec des ressources limitées.
- **Property Price to Income Value (Prix de l'immobilier par rapport au revenu) :** L'accès à un logement abordable est une priorité.
- **Health Care Value (Santé) :** L'accès à des soins de santé gratuits ou abordables est crucial.

- **Safety Value (Sécurité) :** Un environnement sûr est important pour se sentir protégé et en sécurité.
- **Traffic Commute Time Value (Temps de trajet) :** L'accès aux services publics et aux opportunités d'emploi est facilité par des transports efficaces.

Les critères des profils « étudiant » et « sans emploi » sont identiques : leurs scores et leurs classements sont donc exactement les mêmes, et les cinq profils ne produisent que quatre classements distincts.

8.6. Représentation de la destination selon la profession




Figure 9: Représentation des pays du monde selon le statut professionnel (non actualisée)

Ce graphique présente l'individu les pays du monde selon son statut professionnel. Il peut ainsi comparer les pays de destination ; il s'agit d'une capture antérieure à la mise à jour (voir les limites ci-dessous).

Une fois les scores actualisés, les rangs calculés sur les 230 pays du fichier final diffèrent fortement selon le profil. Le tableau 1 en donne quelques exemples.

Tableau 1 : Rang de quelques pays selon le classement général et selon chaque profil (sur 230 pays)

Pays	Général	Étudiant	Salarié	Indépendant	Touriste
Rwanda	228e	188e	38e	181e	1er
Bhoutan	50e	2e	9e	1er	4e
Tuvalu	32e	1er	1er	52e	21e
Luxembourg	1er	52e	15e	37e	37e
Andorre	18e	4e	6e	11e	3e

Le classement général repose sur la variable Quality of Life Value. Le top 10 général partage de zéro à trois pays avec le top 10 d'un profil donné, et aucun pays ne figure à la fois dans le

top 10 général et dans les top 10 des cinq profils. Ces rangs sont à lire avec prudence : Montserrat, 7e pour le profil étudiant, a 8 indicateurs imputés sur 9, et Wallis And Futuna en a 9 sur 9. Le nombre d'imputations signale une dépendance aux estimations, mais ne constitue pas à lui seul une mesure de fiabilité.

Limites. Les critères de chaque profil sont pondérés à parts égales, hypothèse qui influence les classements. Le modèle n'intègre pas directement les visas, le droit au travail, les frais d'études, les revenus personnels, la langue ni les préférences individuelles : ses résultats ne constituent donc pas une recommandation personnalisée. Enfin, le classeur Tableau et ses captures (figures 1 à 9) n'ont pas été actualisés avec les nouvelles imputations et les nouveaux scores : ces figures correspondent à la version antérieure de la base et ne reflètent pas les résultats ci-dessus.

9- le Storytelling

L'objectif de cette partie est de présenter les indicateurs basiques à travers lesquels un individu peut avoir une idée des réalités d'un pays où il souhaiterait aller. Ensuite, nous lui montrons la qualité de vie de tous les pays. Mieux, nous lui montrons qu'il y a des possibilités de peaufiner ce classement des pays qu'il observe selon la profession. Ceci va clore la présentation en lui offrant la possibilité de faire un choix de façon rationnelle. Ci-dessous, l'interface de début du storytelling.



Figure 10: Interface de début du storytelling

V- APPORT DES MEMBRES A LA REALISATION DU PROJET

Nous avons réalisé le projet à travers 4 réunions de travail. La première réunion à consister à prendre connaissance de la base et élaborer un plan d'apurement de la base de données. Cette

réunion s'est soldée par des propositions d'objectifs et des méthodes d'apurement de la base de données.

Le Membre **KONE Abdoulaye** a eu la charge de l'apurement de la base de données.

Une fois la base de données apurée, nous nous sommes à nouveau rencontrés pour constituer les feuilles qui vont servir au Dashboard.

La troisième rencontre à consister à l'élaboration du Dashboard et du storytelling.

Enfin, lors de la dernière rencontre, nous avons réalisé le narratif et les notes sur les feuilles, Dashboard et le storytelling. Pour la constitution des tableaux nous avons échangé les idées et proposé les indicateurs.

En dehors des séances en groupe, **KOUASSI Yao Kra Emmanuel** travaille sur la création des variables pour la classification selon la profession. Monsieur **ADDOH N'chot Serge** à contribuer à parfaire la présentation des tableaux de bord, les couleurs et écriture en dehors des séances de groupe.

CONCLUSION

Ce projet nous a permis de comprendre davantage le cours de Datavisualisation. Nous avons pu prendre connaissance des défis que l'on peut couramment rencontrer dans l'élaboration des tableaux de bord depuis l'apurement jusqu'à la mise en place d'indicateurs ayant un sens pour l'utilisateur. Ce fut assez enrichissant pour chacun des membres de l'équipe.

Sources des données. Quality of Life for Each Country, Kaggle :

<https://www.kaggle.com/datasets/ahmedmohamed2003/quality-of-life-for-each-country>. Ces données de qualité de vie proviennent de Numbeo ; leur utilisation reste soumise à ses conditions d'utilisation : <https://www.numbeo.com/premium/commercial-license>.

World Population Dataset, Kaggle :

<https://www.kaggle.com/datasets/iamsouravbanerjee/world-population-dataset> (licence indiquée sur la page Kaggle : « Other »).

Tables des illustrations

Figure 1: Représentation de la variable "Safety" (non actualisée) -----	3
Figure 2: Reproduction de la variable pollution par pays (non actualisée)-----	4
Figure 3: Représentation des autres variables de la base (non actualisée) -----	4
Figure 4: Représentation de la qualité de vie par pays (non actualisée) -----	5
Figure 5: Représentation de la catégorie du niveau de « Safety » dans le monde (non actualisée)-----	5
Figure 6: Représentation de la pollution par continent (non actualisée)-----	6
Figure 7: Tableau de bord 1 (non actualisée)-----	6
Figure 8: Tableau de bord 2 (non actualisée)-----	7
Figure 9: Représentation des pays du monde selon le statut professionnel (non actualisée) ---	9
Figure 10: Interface de début du storytelling -----	10